**프로젝트 조율 / 진행 상황 요약**

**아키텍처 결정 및 시스템 설계**

- 실시간 분석 대신, 피드백 요청 시점에만 내부 엔진이 분석 수행
  - 회의 중 지속적 실시간 분석을 제거하고, 사용자가 피드백을 요청할 때에만 현재 회의 텍스트+회의 계획서(사전 도메인 분석 결과)를 통합해 내부 엔진이 민감도 분석/마스킹/요약을 수행
  - 캐시화된 도메인 정보(전역)와 회의 요약본·텍스트를 활용해 LLM에 넘기기 좋은 형태로 정리
- 엔진 구성(하이브리드)
  - SLM(예: Ollama)
    - 역할: 회의 중 백그라운드 문제 분석(정체 여부, 반복 키워드 등), 경량 요약(선택), 내부 데이터 구조화
    - 팁 제공은 품질/필터 이슈로 축소 검토(필요 시 강한 프롬프트 설계)
  - 대형 언어 모델 (LLM)
    - 역할: 피드백(요청 시), 회의 종료 후 정교한 회의록·To-do 생성
    - 입력: 회의 텍스트+SLM 문제 분석 메타(정체 정도, 반복 키워드 등)
    - 출력 전 민감정보 필터/마스킹 적용
- 도메인 분석(사전)
  - 회의 계획서 입력 기반으로 내부 엔진이 도메인(주제/섹터) 추출 및 전역 캐시화
  - 이유: 필터 정책(섹터별 민감도) 적용을 위해 LLM이 아닌 내부 엔진에서 수행
- 민감정보 필터링
  - 외부로 나가기 전 단계에 필터 필수(붉은 체크로 표기된 경계)
  - 내부 엔진에서 민감 태그 부착→마스킹 후 LLM 요청
  - 출시 전 필수 적용, 파일럿/실험 단계에서는 일시적 생략 가능(외부 유출 허용 가정)

- RAG/검색 및 외부 정보
  - SLM 자체의 웹 검색 기능은 불필요
  - 필요 시 내부 검색/RAG 모듈(사내 DB/검색 API 연동)로 외부 정보 조회(데이터 유출 없음 가정)
  - 회의 맥락 보완용으로 회의 후 이미지/PPT 업로드 지원(맥락 정정/보강)
- 입력/파이프라인 개요
  - 전(회의 시작 전): 회의 계획서 업로드→도메인 분석(전역 캐시)
  - 중(회의 중): 음성→STT(+VAD)→텍스트 저장, SLM이 문제 분석 메타 생성(경량), 사용자가 피드백 요청 시 LLM 호출
  - 후(회의 종료 후): 저장된 전체 오디오를 고성능 STT로 재처리→필터→LLM→최종 회의록/To-do 산출
- 저장/데이터 관리
  - DB 저장 대상: 도메인 분석 결과, 회의 텍스트(STT), SLM 문제 분석 메타, 팁(선택), 피드백 결과, 최종 회의록/To-do
  - 데이터 교환 포맷: JSON(변경 가능성 고려)
- 파일/형식 지원
  - 문서: PDF, HWP, DOC, PPT
  - 오디오: MP3, WAV
  - 이미지: PNG, JPG(텍스트 추출 보조)
- 기술 스택/연동
  - STT/VAD 파이프라인 준비됨(정확도 향상 위해 회의 후 재처리 사용)
  - 모델: SLM(Ollama) 우선, LLM(GPT API 등) 연동 옵션화
  - 서버: Python, Node.js 혼용(백엔드 연계, DB I/O 정합성 확보)

**UI/UX 범위와 우선순위**

- 실시간 회의방(우선 구현)
  - 기능: 회의 시작/종료 토글, 피드백 요청 토글, 회의 계획서 참조, 자료 업로드(후순위), 회의 종료 후 결과 워크스페이스로 전송

- 워크스페이스
    - 공용: 회의록 보관/열람, 자료 업로드(후순위), 캘린더 기반 과거 회의 조회
        - 캘린더 확장: 회의 일정 추천(참여자 시간 중복 확인)
    - 개인: 탭 분리(태스크별), 개인 To-do 관리(선택), AI 사이드바와 연동하여 문맥형 팁 요청 가능
- AI 사이드바
    - 사용자 요청 시 AI 질의 가능(LLM/SLM 선택적 활용)
- 실시간 채팅
    - 우선순위 하향(카카오톡 대체 기능은 초기 범위 제외)
- 계획서 입력 위치
    - 회의방/공용 워크스페이스 양쪽에서 사용 가능
    - "워크스페이스에서 불러오기 vs 로컬 업로드" 선택 UX 제공
- 사용자 상호작용(피드백 요청)
    - 기본: "정체 발생" 클릭만으로 요청(문제 분석은 모델이 수행)
    - 보완: 필요 시 사용자가 간단한 문제 설명을 추가 입력할 수 있도록 옵션 제공(오분석 방지)

**미해결 질문 및 위험 요소**

- 팁의 실시간 자동 제공
    - SLM 품질/속도·필터 부담 고려 시 초기 축소 필요
    - "야, 그게 뭐였지?" 유형의 명시적 요청에만 LLM 호출하는 방식으로 대체 검토
- 화자 분리(VAD/diarization) 정확도
    - 개인별 To-do 자동 분배는 신뢰도 낮음→일반 To-do 리스트 중심으로 제공
- 성능 vs 속도 균형
    - SLM 문제 분석 메타를 LLM에 함께 전달 시 추론 방향성 개선(COT 유사 효과) 기대

    - 다만 입력 길이 증가에 따른 지연 가능성→파일럿에서 속도/성능 비교 필요
- 원격 화상 회의 연계
    - 현재 범위에서 제외(추후 추가 시 파이프라인 복잡도 증가 예상)
- 데이터 유출/보안
    - 외부 API 연동 구간에서 필터 우회가 없도록 게이트 엄격화 필요

**타임라인 및 이정표**

- 단기
    - 다음 주 화요일까지: 현재 범위 내 구현 진척 최대화(연결 파이프라인 초안)
    - 다음 주 주말까지: 백엔드 기본 구현(필터 제외) 완료 목표, 실험 제외
- 중기
    - 4월 말까지: 주요 기능 구현 완료(파일럿 수준), 이후 2~3주 테스트/튜닝
    - 출시 전: 민감정보 필터 완전 적용 및 튜닝

**할 일 목록**

@Speaker2: 회의 계획서 기반 도메인 분석 모듈 구현(주제/섹터 추출 및 전역 캐시) – 다음 주 화요일까지 초안.

@Speaker1: STT/VAD 파이프라인과 DB 연계, 피드백 요청 토글 연동(LLM 호출 경로 포함) – 다음 주 주말까지.

@Speaker1: SLM(Ollama) 통합 및 문제 분석 메타(정체 정도/반복 키워드 등) 산출 로직 구현 – 다음 주 주말까지.

@Speaker2: DB 스키마/데이터 타입(JSON) 명세 정리 및 공유(텍스트, 도메인, 문제 메타, 회의록, To-do) – 다음 주 화요일까지.

@Speaker5: 회의방 UI 기본 구성(회의 시작/종료 토글, 피드백 요청 토글, 계획서 입력창; 워크스페이스 연동 옵션) – 다음 주 주말까지 와이어프레임.

@Speaker1: 회의 종료 후 고성능 STT 재처리 경로 구현 및 LLM 요약/회의록/To-do 프롬프트 템플릿 구성 – 4월 말까지.

@Speaker2: 민감정보 필터(태깅/마스킹) 알고리즘 프로토타입 설계(출시 전 필수, 파일럿

은 생략 가능) – 4월 말까지 설계안.

@Speaker5: 캘린더 기반 회의 기록 열람 UI 및 일정 추천 기초 설계 – 4월 말까지 초안.

@Speaker1: 파일 입력 형식 처리(PDF/HWP/DOC/PPT, MP3/WAV, PNG/JPG) 파이프라인 점검 – 4월 말까지.

**의제**

회의 시스템 아키텍처 설계 및 구현 방안

AI 모델 역할 분담 및 파이프라인 구성

사용자 인터페이스 기능 요구사항 정의

데이터 필터링 및 보안 처리 방안

개발 일정 및 역할 분배

**회상**

이번 회의에서는 회의 지원 시스템의 전체적인 아키텍처와 구현 방향에 대한 종합적인 검토가 이루어졌습니다. Speaker 1과 Speaker 2를 중심으로 시스템의 핵심 구성요소들과 각 모듈 간의 연결 방식에 대해 심도 있는 논의가 진행되었으며, 특히 AI 모델의 효율적인 활용 방안과 실시간 처리 성능 최적화에 대한 검토가 집중적으로 다뤄졌습니다.

**진행 상황**

Speaker 1이 STT 및 VAD 기능 구현 상태를 보고했으며, 기본적인 음성 처리 파이프라인은 완성된 상태임을 확인했습니다

Speaker 2가 도메인 분석 모듈 구현을 담당하기로 하였으며, 회의 계획서를 입력받아 주제를 분석하는 기능을 개발할 예정입니다

Speaker 5가 SLM 기반 회의 요약 기능을 테스트한 결과, 짧은 회의 내용에 대해서는 양호한 성능을 보였으나 긴 회의에 대한 성능은 추가 검증이 필요한 상황입니다

UI 구현 진행 상황에 대해 Speaker 5가 기본적인 채팅 인터페이스는 구현되어 있으나 정리 작업이 필요하다고 보고했습니다

**문제점**

문제: SLM의 실시간 분석 처리로 인한 시스템 리소스 부담

해결방안: 피드백 요청 시에만 내부 엔진이 동작하도록 변경하여 실시간 부하를 줄이는 방식 채택

문제: 외부 LLM 사용 시 민감 정보 유출 위험

해결방안: 외부 전송 전 필터링 시스템을 구축하여 민감 데이터를 마스킹 처리하는 방안 도입

문제: SLM의 웹 검색 기능 부재로 인한 팁 제공 기능 제한

해결방안: RAG 시스템을 통해 웹 검색 기능을 별도로 구현하여 SLM과 연동하는 방식 채택

문제: 회의 중 실시간 처리 속도와 정확도 간의 트레이드오프

해결방안: 회의 중에는 가벼운 모델을 사용하고 회의 후에는 고성능 모델로 재처리하는 하이브리드 방식 도입

문제: 발화자 분리 성능의 한계로 인한 개인별 할일 분배 어려움

해결방안: 개인별 할일 분배보다는 전체 할일 목록을 제공하고 사용자가 직접 선택하는 방식으로 변경

**결정 사항**

실시간 분석 대신 피드백 요청 시에만 내부 엔진이 동작하는 방식으로 시스템 아키텍처를 변경하기로 결정했습니다

LLM은 피드백과 요약 기능을 담당하고, SLM은 팁 제공과 문제 분석 기능을 담당하는 역할 분담을 확정했습니다

회의 계획서는 공용 워크스페이스에서 관리하되, 회의방에서 불러올 수 있는 방식으로 UI를 구성하기로 했습니다

필터링 기능은 개발 후순위로 미루고, 우선 핵심 기능 구현에 집중하기로 결정했습니다

다음 주 주말까지 필터 기능을 제외한 백엔드 구현을 완료하는 것을 목표로 일정을 설정했습니다

실시간 채팅 기능은 구현 우선순위에서 후순위로 조정하고, 핵심 회의 기능 구현을 우선하기로 했습니다

**프로젝트 동기화 / 상태 업데이트 요약**

**개요**

- 본 회의는 회의 보조 제품의 아키텍처와 구현 범위를 정리하고, 실시간(회의 중) 처리와 회의 후 처리의 역할 분담, 모델 선택(SLM vs LLM), 민감정보 필터 적용

시점, 입력/출력 데이터 타입, UI/UX 우선순위, 일정과 역할 분장을 확정하는 데 초점을 맞추었다.

**아키텍처 및 처리 흐름**

- 전체 파이프라인 개요
  - 회의 전(Pre): 회의 계획서로 도메인(주제, 맥락) 분석 → 전역 컨텍스트 생성/캐시.
  - 회의 중(In-Meeting): Zoom 오디오 → VAD(발화/정적 구분, 화자 분리) + STT(ASR) → 텍스트화 → SLM이 경량 문제 분석(정체 정도, 반복 키워드 등)과 구조화 수행 → DB에 지속 저장.
  - 피드백 시(On-demand): 사용자가 피드백 버튼을 누르는 시점에 한해 내부 엔진이 현재까지의 텍스트, 요약본, 도메인 정보를 통합 → 민감 태그 식별 및 마스킹 → LLM에 전달해 고품질 피드백 생성.
  - 회의 후(Post): 저장된 전체 오디오를 고성능 STT로 재처리 → LLM으로 고품질 회의록/To-do 생성 및 주제별 구획화(Topic 1, 2, 3...) → 워크스페이스에 게시.
- 내부 엔진 분리와 캐시
  - 도메인 분석 엔진(회의 전): 회의 계획서 기반 전역 도메인 변수/주제 도출(가벼운 리소스로 선분석).
  - 회의 분석 엔진(요청 시): 민감도 분석/마스킹, 요약 결합, LLM 입력 최적화(캐시된 전역+현행 정보 합본으로 즉시 사용).
- 실시간 상시 분석 최소화
  - 내부 엔진을 상시 가동하지 않고, 사용자 피드백 요청 시에만 가동해 리소스 절감.
  - SLM은 백그라운드에서 경량 분석/구조화에 집중(지속 저장 기반), LLM 호출은 필요 시에만.

**모델 및 구성 요소 역할**

- SLM(예: Ollama, 로컬)
  - 역할: 실시간 텍스트 구조화, 경량 문제 분석(정체 감지, 빈도 키워드 등), 빠른 요약(선택적), LLM 입력 보조 정보 생성(CoT 프롬프트 보강용 문맥).

    - 비역할: 웹 검색 필수 아님. 팁(Tips) 기능은 실험적(노이즈/필터 이슈로 우선순위 낮음).
- LLM(예: GPT API 등, 외부)
    - 역할: 피드백(요청 시), 회의 후 고품질 요약/회의록/To-do, 주제 구획화, 상세 분석.
    - 입력: 텍스트(요약본 포함), SLM의 문제 분석 결과(정체/반복정보 등)와 도메인 정보(민감 마스킹 후).
- RAG/검색
    - 정의 정리: RAG는 내부 문서/청크 기반 검색-응답 파이프라인(웹 검색과 별개).
    - 웹 검색 모듈은 필요 시 별도 API로 접속(예: "점심 장소" 등 맥락성 외부 정보)하되, 내부 DB와 분리해 데이터 유출 방지.
    - 현 단계: SLM에 웹 검색을 붙이지 않음(필요 시 LLM/별도 모듈 경유).

**민감성과 개인정보 보호**

- 민감도 필터
    - 민감 태그 식별 및 마스킹은 외부 호출 전 필수(프로덕션 기준).
    - 프로토타입/실험 단계에서는 필터 우회 가능(출시 전 반드시 재적용 및 튜닝).
- 적용 시점
    - 피드백 요청 시: SLM/도메인/텍스트를 합본 후 민감 마스킹 → LLM 전달.
    - 회의 후: 고성능 STT로 재생성된 텍스트에도 동일하게 마스킹 후 LLM 처리.
- 데이터 경계
    - 내부 DB에 모든 원천/중간 산출물을 저장하되, 외부 API 호출 전 민감정보 제거.
    - 검색 모듈은 내부에서 프록시로 동작해 사내 데이터가 외부로 직접 유출되지 않도록 설계.

**입력, 파일 형식 및 출력**

- 입력(최소 구동 기준)
    - 음성: Zoom 오디오 스트림(회의 중), 저장 오디오(회의 후 재처리).
    - 문서: 회의 계획서(필수), 회의 자료(후순위).
- 지원 파일 타입(초기 목표)
    - 문서: PDF, HWP, DOC, PPT.
    - 이미지: PNG, JPG(텍스트 추출 보조).
    - 오디오: MP3, WAV.
- 출력
    - 회의 중: 구조화 텍스트(발화 로그), 경량 요약(선택), 문제 분석 메타데이터(정체/반복 등).
    - 피드백(요청 시): 민감 마스킹된 문맥+분석 정보 기반 LLM 피드백.
    - 회의 후: 고품질 회의록, To-do 리스트, 주제별 구획/결정사항/이슈-해결 내역.

**데이터베이스 및 데이터 흐름**

- 저장 원칙
    - 원천/중간/최종 결과 모두 DB 저장: 도메인 분석, 발화 텍스트, 문제 분석 결과, 팁(있을 경우), 피드백, 요약/회의록, To-do.
    - 회의방/워크스페이스 단위로 이력 축적(캘린더/과거 조회에 활용).
- 데이터 타입/인터페이스
    - 서비스 간 인터페이스는 우선 문자열/JSON 기반 표준화.
    - 모델 입력/출력 타입을 조기 합의해 추후 교체/확장 용이성 확보.

**UI/UX 범위 및 우선순위**

- 실시간 회의방(우선)
    - 회의 계획서 입력(워크스페이스에서 불러오기/로컬 업로드 선택), 회의 자료 업로드(후순위).
    - 토글: 회의 시작/종료(녹음), 피드백 요청.

    - 회의 종료 후 자동으로 회의록/To-do를 공용 워크스페이스에 게시.
- 워크스페이스
    - 공용: 회의록/To-do 이력, 자료 업로드, 캘린더(과거 회의 열람), 회의 일정 추천(캘린더 겹침 고려), 태스크 진행률(수기 입력).
    - 개인: 개인 메모/탭(태스크 단위 구성), 개인 To-do 관리, 필요 시 AI 사이드바와 연동한 요청형 팁.
- 채팅/화상
    - 사용자 간 실시간 채팅은 후순위(카카오톡 대체 필요성 낮음).
    - 원격 음성회의 기능은 복잡도/성능 이슈로 후속 검토.

**실행 계획 및 일정**

- 구현 우선순위(백엔드 중심)
    - 1) STT/VAD 파이프라인(회의 중), 2) 도메인 분석(회의 전), 3) DB 스키마/저장, 4) 피드백 요청 트리거와 LLM 연동(민감 마스킹 후), 5) 회의 후 고성능 STT 재처리 및 회의록/To-do 출력.
    - 필터는 출시 전 반드시 적용/튜닝(실험 단계에서는 우회 가능).
- 모델/기술 스택
    - SLM: Ollama 중심(로컬), LLM: GPT API 등 외부(대체 가능하게 래핑).
    - 언어: Python(핵심 처리/모델 연동), Node.js(서버/API). 데이터 교환: JSON.
- 일정 합의
    - 다음 주 화요일까지: 각자 가능한 범위 최대 구현.
    - 다음 주 주말까지: 필터 제외 백엔드 주요 기능 통합(실험 제외).
    - 4월 말까지: 기능 개발 완료 권장 → 이후 2~3주 테스트/수정.

**실험 및 검증**

- 파일럿 테스트 항목
    - SLM 문제 분석 보강정보 유무에 따른 LLM 응답 속도/정확도 비교(CoT 보강 효과).
    - 실시간 요약 주체(SLM vs LLM) 별 응답 지연/품질 비교.

    - 화자 분리(VAD) 품질과 개인별 To-do 자동 분배 가능성 검토(현재는 목록 중심으로 단순화).
- 성공 기준
    - 피드백 요청 시 체감 대기시간 허용 범위 내 유지.
    - 회의 후 회의록/To-do 품질이 실사용 만족 기준 충족.
    - 민감정보 마스킹 효과 검증(출시 전).

**미해결 질문과 결정사항**

- 확정
    - 피드백은 사용자가 명시적으로 요청하는 온디맨드 방식.
    - SLM은 실시간 경량 분석/구조화, LLM은 고품질 피드백/회의 후 요약 담당.
    - 초기 AI 입력은 음성(STT) + 회의 계획서에 집중(회의 자료는 후순위).
    - 실시간 사용자 채팅은 후순위. 필터는 출시 전 적용.
- 보류/검토
    - SLM의 팁 기능(상시 제안) 지속 여부: 실험 후 노이즈/효용 평가.
    - 회의 자료(PPT/이미지) 실시간 반영 범위와 RAG 결합 방식.
    - 원격 음성회의 기능 포함 여부(복잡도/성능 고려).
    - 로그인/세션/방 관리 도입 시점(후속 스프린트).

**실행 항목**

@백엔드: 회의 중 STT/VAD 파이프라인 연결(Zoom 오디오 입력→텍스트 저장) 및 SLM 연동.

@백엔드: 회의 전 도메인 분석 모듈 구현(회의 계획서→주제/도메인 추출) 및 DB 저장.

@백엔드: 피드백 요청 트리거 구현(토글) 및 민감 마스킹→LLM 호출 파이프라인 연결.

@백엔드: 회의 후 고성능 STT 재처리 배치 구성(저장 오디오→정정 텍스트→LLM 회의록/To-do).

@데이터: DB 스키마/인터페이스(JSON) 정의(발화 텍스트, 도메인, 문제 분석, 요약/회의록, To-do 등).

@프론트엔드: 회의방 UI 구현(회의 계획서 입력, 회의 시작/종료 토글, 피드백 요청 토글, 자료 업로드 칸).

@프론트엔드: 공용 워크스페이스 화면(회의록/To-do 게시, 과거 회의 조회 기본 뷰) 초안.

@모델: Ollama 기반 SLM 환경 구성 및 프롬프트 템플릿 초안(문제 분석/구조화 중심).

@모델: LLM 연동 래퍼 설계(GPT API 우선, 교체 가능 구조)와 마스킹 전/후 체인 정리.

@QA: 파일럿 테스트 설계(속도/정확도 비교: SLM 보강 유무, 요약 주체별 차이) 및 로그 수집 계획.

@팀: 지원 파일 타입 확정(PDF/HWP/DOC/PPT, PNG/JPG, MP3/WAV) 및 파서/추출 경로 점검.

@팀: 일정 준수(다음 주 화요일 1차 점검, 다음 주 주말 백엔드 통합, 4월 말 기능 완료 목표).